

# Segmentación semántica y de instancias de órganos del tracto gastrointestinal


## Visión por Computadora II - CEIA

Diego Tomás Gomila Molina  
Trinidad Monreal

# Descripción del problema




## UW-Madison GI Tract Image Segmentation

- 5 millones de personas diagnosticadas con cáncer del tracto gastrointestinal (2019).
  - 2.5 millones → elegibles para radioterapia.
- Radiación en altas dosis al **tumor** evitando el **estómago** y los intestinos.
  - Tecnología MR-Linacs → oncólogo debe delinear manualmente la posición de los órganos (15 - 60 min).
- **Objetivo:** segmentar intestino grueso, intestino delgado y estómago empleando técnicas de visión por computadora.




## Dataset UW-Madison GI Tract Image Segmentation

- Dividido por casos y días de muestra.
  - En general → 140 *slices* cada día.

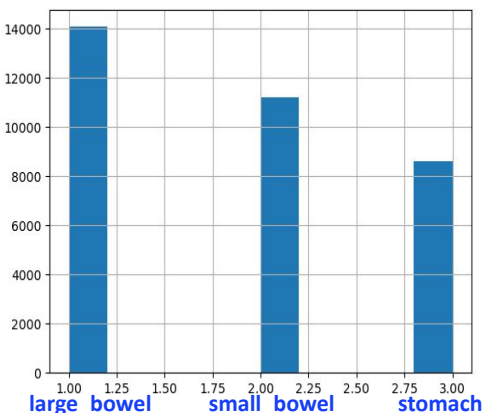


# Dataset UW-Madison GI Tract Image Segmentation


- 38.496 imágenes PNG en escala de grises de 16 bits. Resolución promedio: 293 x 279 px.
  - Imágenes con al menos una máscara: 16.590.
  - En total: 33.913 máscaras de 3 clases diferentes: “large\_bowel”, “small\_bowel” y “stomach”.



Cantidad de imágenes



Máscaras por clases



# img con máscaras por área

# Modelos a entrenar

## Segmentación semántica: U-Net

- 1) Modelo clásico usando PyTorch.
- 2) Modelo con backbone pre-entrenado usando Segmentation Models.


## Segmentación de instancias: MASK R-CNN

- 1) Modelo clásico.
- 2) Modelo con backbone actualizado y aumento de datos.

# Aumento de datos

## U-Net

- Horizontal flip
- Vertical flip
- Grid Distortion
- Elastic Transform
- Random Brightness




## MASK R-CNN

- Random flip: 50%
- Random zoom out: 30%
  - Rango: 1 a 1.2
- Random Photometric Distort: 30%
  - Contrast: 0.875 a 1.125
  - Brightness: 0.875 a 1.125
- Random IoU Crop: 100%
  - Escala: 0.9 a 1.1
  - Relación de aspecto: 0.9 a 1.1

# Mask R-CNN

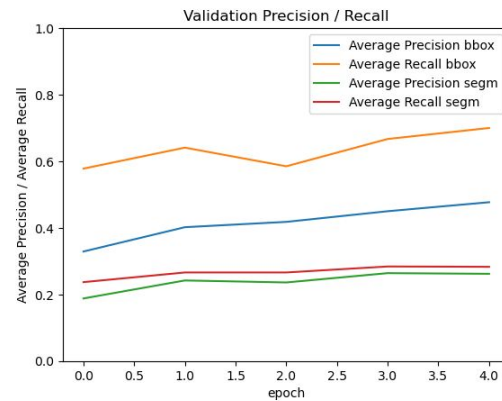


## Modelo clásico

- Backbone: ResNet50
- Parámetros: 43.933.159
- lr\_scheduler: 0.0005, disminuye cada 3 épocas
- Pesos pre entrenados:
  - Database: COCO2017
  - categorías 90
  - box\_map (on COCO-val2017) 37.9
  - mask\_map (on COCO-val2017) 34.6



# Mask R-CNN

## Entrenamiento












# Mask R-CNN

Resultados

Imágenes + máscaras



Predicciones



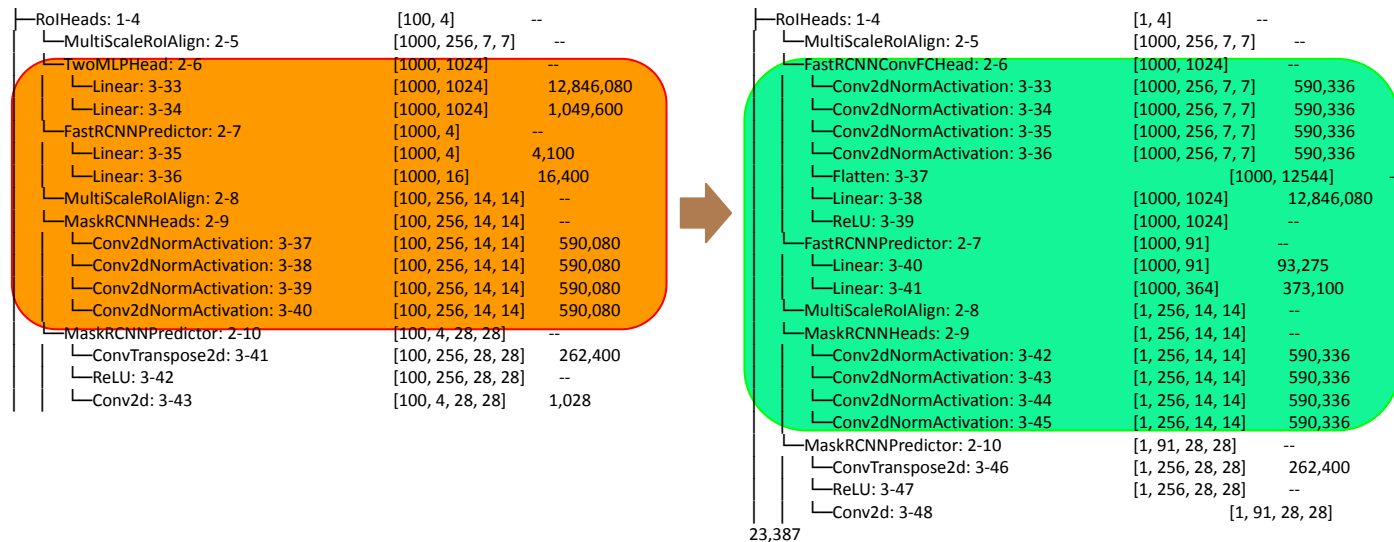
# Mask R-CNN v2

## Modelo modificado

- Backbone: ResNet50
- Parámetros: 46.359.409
- Pesos pre entrenados:
  - Database: COCO2017
  - categorías 90
  - box\_map (on COCO-val2017) 47.4
  - mask\_map (on COCO-val2017) 41.8




# Mask R-CNN v2

## Modelo modificado



# Mask R-CNN




## Entrenamiento







# Mask R-CNN

Resultados

Imágenes + máscaras



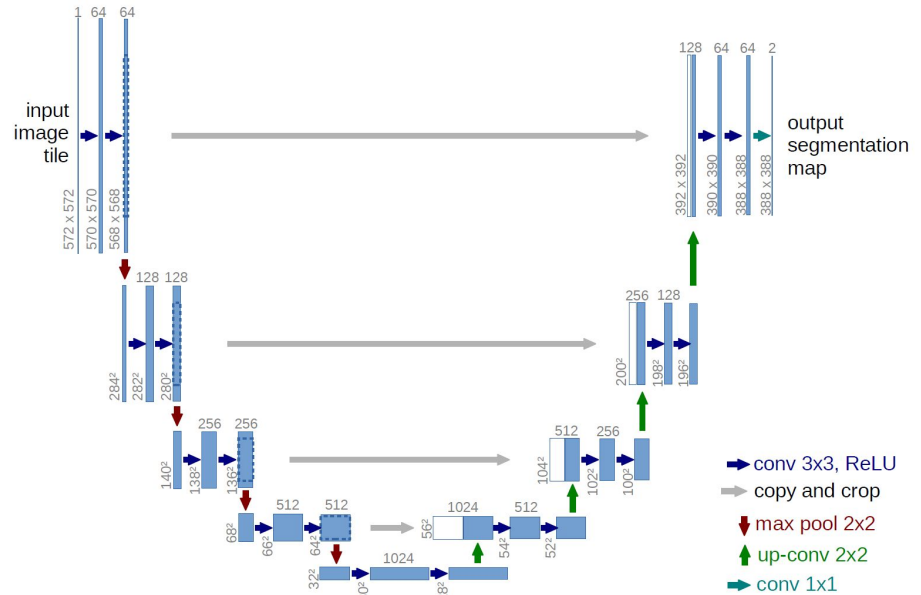
Predicciones



# U-Net

## Modelo 1

- Learning rate scheduler
- Parámetros: 30,101,475
- Dice Loss Function

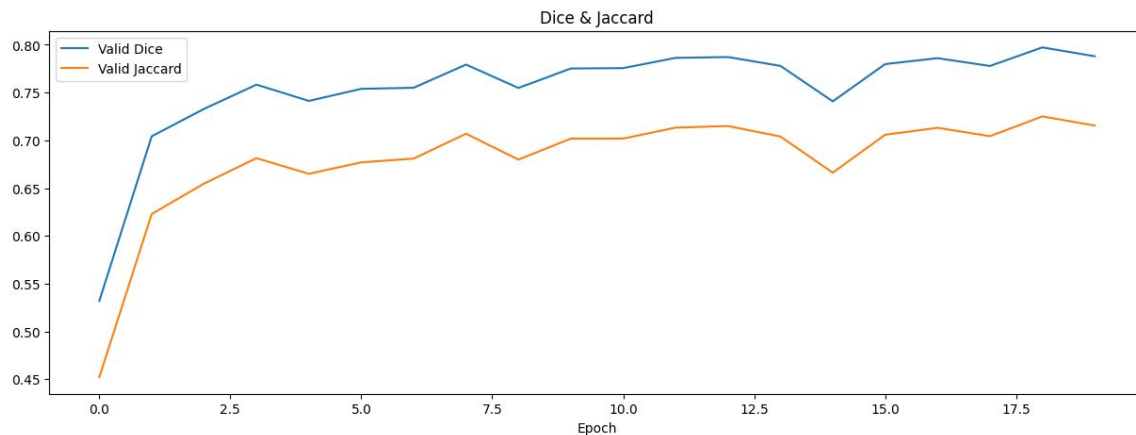



Ronnemberg et al, U-Net: Convolutional Networks for Biomedical Image Segmentation

# U-Net

## Entrenamiento





- Valid Dice: 0.7973
- Valid IoU: 0.7251







# U-Net

## Resultados

Imágenes + máscaras



Predicciones

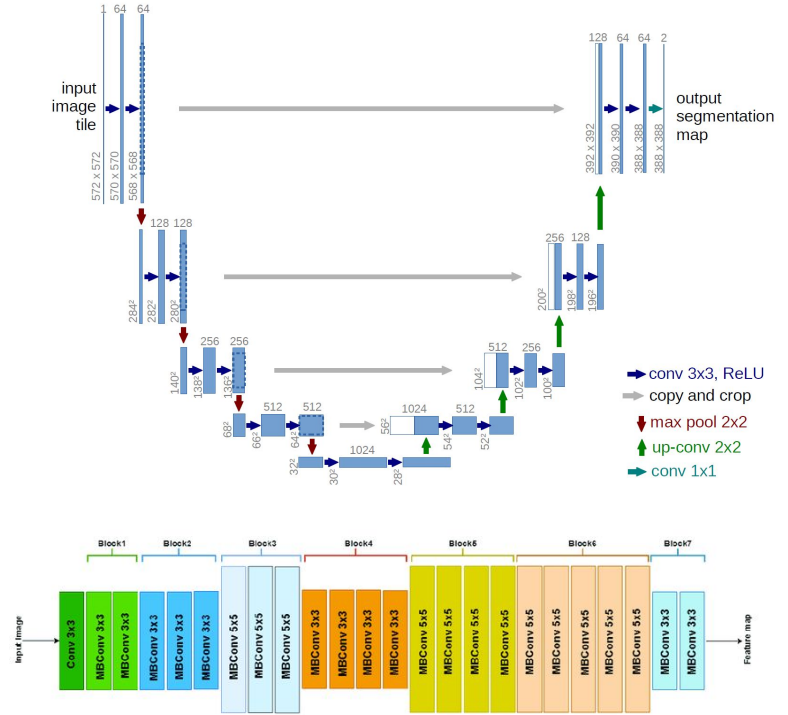




# U-Net

## Modelo 2



- Backbone: EfficientNet-B1
  - Pre entrenamiento en ImageNet



# U-Net

## Entrenamiento





- Valid Dice: 0.8087
- Valid IoU: 0.7352







# U-Net

Resultados

Imágenes + máscaras



Predicciones



# Conclusiones

- Se logró realizar la tarea de segmentación con diferentes grados de éxito.
- MASK R-CNN
  - El transfer learning realizado ha logrado disminuir en gran medida el tiempo de entrenamiento necesario.
  - El aumento de datos permite extender el entrenamiento por más épocas antes de llegar a un sobre entrenamiento.
- U-Net
  - El transfer learning realizado no aportó mejoras significativas en el tiempo de entrenamiento ni las métricas obtenidas sin él.
- Ambos modelos pueden mejorar si se realizan entrenamientos durante un tiempo más prolongado.